



最优 FDR 控制：基于 Compound-Decision Framework (Adaptive z-value procedure)

决策框架
本文基于决策理论的框架提出最优的 FDR 控制方法 (基于 z 值, min mFNR, s.t. mFDR ≤ α)
① 将决策问题等价为一个分类问题, 后者可解, 进而转换为决策问题, 为 $\delta(Lfdr(\cdot), c) = \{I[Lfdr(x_i) < c] : i=1, \dots, m\}$. 因为 $Lfdr(\cdot) = \frac{(1-p)f_0(\cdot)}{f(\cdot)}$, 这和 p 值方法不同.
Lfdr 不仅考虑了全局特征 p, 和局部特征 $\frac{f_0}{f}$, 且由 Lfdr 意味着对“相对重要性”进行排序根据似然比. 而对 p 值排序是要 Alternative 关于 null 对称, 而决策理论可用在非对称情形 (有这种可能: 一个距离 null 很近的观测可能显著性水平很低, 在用 Lfdr 准则下, 即该检验可以接受更多极端的假设, 拒绝更多不极端的假设, 即拒绝域不是对称的)

由此可知该方法是最优的
② 利用 $mFDR = FDR + o(m^{-1/2})$, 现要决定 cutoff. 因为 $mFNR \downarrow, mFDR \uparrow$. 故当 $mFDR = \alpha$ 时 $mFNR$ 取 min. 又因为 $mFDR, (Q(\alpha))$ 是阈值 λ 的增函数, 故 $\lambda_{\text{opt}} = \sup\{\lambda \in (0, 1) : Q(\lambda) \leq \alpha\} = Q^{-1}(\alpha)$
③ 但是 p, f_0, f 需要估计 (Jin, Cat, 2007), 由于 Efron (2007) 指出, FDR 为 fdr 在 $z \leq z$ 的条件期望 (积分-间距距为 $\frac{1}{m}$, 或简单理解为条件样本均值), 估计 $\hat{Q}_{\text{DR}}(Lfdr(x)) = \frac{1}{m} \sum_{i=1}^m Lfdr(x_i)$ 但 λ_{opt} 不好估计, 故跳过. 找 $k = \max\{i : \hat{Q}_{\text{DR}}(Lfdr(x_i)) \leq \alpha\}$, 拒绝 $H_{(1)}, \dots, H_{(k)}$.

2. 假设前提. ① $f > 0$ on real line, f 连续 ② $T_{\text{OR}}(z) = \frac{(1-p)f_0(z)}{f(z)}$ 的连续 pdf 为 $q = (1-p)q_0 + pq_1$
③ $T_{\text{OR}} \in \mathcal{T}$ 满足 SMLR 假设 (plug-in 方法要求 Q_1 为凹函数, 此为假设的一般化)
④ $p \rightarrow p, E\|f - \hat{f}\|^2 \rightarrow 0, E\|f_0 - \hat{f}_0\|^2 \rightarrow 0$

NOTE: Plug in 方法不能对 z 值方法使用, 因为不知道 T_{OR} 的分布 (需要估计). 而 z 值分布一般为混合正态模型. z 值方法 (本文) 有效的原因是从 single rule 拓展到 compound rule 中去考虑.

3. 理论结果

命题一 (该命题说明了 SMLR 假设保证了多重检验以及分类问题的良好性质)
设 $\theta_i \in B(0, p), i=1, \dots, m$ 设 x_i 为 $X_i | \theta_i, i=1, \dots, m$ 为模型 $[X_i | \theta_i \sim (1-\theta_i)F_0 + \theta_i F_1]$ 的独立观测. 设 $T \in \mathcal{T}$ (下降的 MLR), 则 $\delta(T, c) = \{I[T(X_i) < c], i=1, \dots, m\}$ (无论是多重检验还是分类问题), 有如下性质:
(a) $P(\theta_i = 1 | T(X_i) \leq c)$ 为阈值 c 的单调降函数.
(b) $mFDR$ 为阈值 c 和拒绝总数期望 r 的增函数
(c) $mFNR$ 为 c 和 r 的减函数
(d) $mFNR$ 随着 $mFDR$ 的上升而下降.
(e) 在分类问题中, c 和 r 随着分类权重 λ 的上升而下降.



证明: (a) $\because T$ 有单调减的 MLR. $\therefore \int_{-\infty}^c g_0(t)dt / \int_{-\infty}^c g_1(t)dt = \int_{-\infty}^c g_0(t)dt / \int_{-\infty}^c \frac{g_1(t)}{g_0(t)} g_0(t)dt$
 $< \int_{-\infty}^c g_0(t)dt / \int_{-\infty}^c \frac{g_1(c)}{g_0(c)} g_0(t)dt = \frac{g_0(c)}{g_1(c)}$

对 $G_0(c)$ 对 $T(X)$ 的 cdf. $F_0(x)$ 对 X 的 cdf

再由分布函数定义. 有 $g_1(c)G_0(c) < g_0(c)G_1(c)$

对 $P(\theta_1=1 | T(X) \leq c) = \frac{P G_1(c)}{G_1(c)}$ 中 c 求导, $\frac{(1-p)P[g_1(c)G_0(c) - g_0(c)G_1(c)]}{G_1(c)^2} < 0$

(b), (c) 类似可证, 其中 $mFDR = \frac{p_0 G_0(c)}{G_1(c)}$, $mFNR = \frac{p_1(1-G_1(c))}{1-G_1(c)}$

由 (b), (c) 即证 (d)
 (e), 易得分类风险 $R_\lambda = E(L_\lambda(\theta, \delta)) = \lambda(1-p)G_0(c) + p[1-G_1(c)]$, 易求得使风险最小的阈值满足 $\lambda = \frac{p g_1(c^*)}{(1-p)g_0(c^*)}$, 由 MLR 性质, λ 是 c 的减函数. $v = G_1(c^*)$ 为 c^* 的增函数. $\therefore \lambda$ 是 v 的减函数.

定理一 (多重检验问题与分类问题等价). $\theta_i, x_i | \theta_i$ 同前, 令 $\Lambda \in \mathcal{T}$. 设分类损失函数 $L_\lambda(\theta, \delta) = \frac{1}{m} \sum_{i=1}^m [\lambda I(\theta_i=0)\delta_i + I(\theta_i=1)(1-\delta_i)]$ 最小化时对应 $\{\delta_1^*, \dots, \delta_m^*\}$, $\delta_i^* = I[\Lambda(x_i) < c(\lambda)]$ 对任意水平为 α 的 mFDR 多重检验, 存在唯一 $\lambda(\alpha)$, 其对应分类问题的最优解 $\{\delta_i^*\}_{i=1}^m$ 也是多重检验问题的最优解. 即 $\min mFNR$ s.t. $mFDR \leq \alpha$. 对所有 \mathcal{D}_S 中的决策 (SMCR 决策)

定理二 (分类问题的最优解) $\theta_i, x_i | \theta_i$ 同前. 设 p, f_0, f_1 已知. 分类最优解为

$\delta_i = I[\Lambda(x_i) = \frac{(1-p)f_0(x_i)}{pf_1(x_i)} < \frac{1}{\lambda}]$, $i=1, \dots, m$. [显然, i.e. $\lambda(1-p)f_0 < pf_1$, 拒绝 H_0 , 做 H_1 的决定]

检验方法: 令 $k = \max\{i, \frac{1}{\alpha} \sum_{i=1}^m \hat{L}_{fdr}(y_i) \leq \alpha\}$, 拒绝 $H_0^{(i)}$, $i=1, \dots, k$. $mFDR$ 的估计.

定理三 (检验方法的渐近有效性) $\theta_i, x_i | \theta_i$ 同前. pdf 为 $f = (1-p)f_0 + pf_1$. 设 $f \in C^1$, $f > 0$. 设 $T_{OR}(z_i) = \frac{(1-p)f_0(z_i)}{f(z_i)}$ 的 mpdf 为 $g = (1-p)g_0 + pg_1$, $T_{OR} \in \mathcal{T}$ 满足 SMCR 假设. 设 $\hat{p}, \hat{f}_0, \hat{f}_1$ 分别为 p, f_0, f_1 的估计, 满足 $\hat{p} \xrightarrow{P} p$, $E\|\hat{f} - f\| \rightarrow 0$, $E\|\hat{f}_0 - f_0\| \rightarrow 0$. 定义检验统计量 $\hat{T}_{OR}(z_i) = \frac{(1-\hat{p})\hat{f}_0(z_i)}{\hat{f}(z_i)}$, 设 $L_{fdr(1)}, \dots, L_{fdr(m)}$ 为 $\hat{T}_{OR}(z_i)$ 的排序结果, 则上述检验方法渐近将 mFDR 控制在水平 α 下.

定理四 (检验方法的最优性). 符号同定理三, 则检验方法的 mFNR 水平渐近为 $\tilde{Q}_{OR}(\lambda_{OR}) + o(1)$, $\tilde{Q}_{OR}(\lambda_{OR}) = \frac{p \tilde{G}_{OR}(\lambda_{OR})}{\tilde{G}_{OR}(\lambda_{OR})}$ 为 Oracle 情形下 Z 值方法的 mFNR 水平.

为证明 Thm 3 和 Thm 4, 需先证明下面几个引理.



引理 - 设 $\beta, \hat{f}, \hat{f}_0$ 满足 $\beta \xrightarrow{P} p, E\|\hat{f}_0 - f\| \rightarrow 0, E\|\hat{f} - f\| \rightarrow 0$, 则有 $E\|\hat{T}_{OR} - T_{OR}\|^2 \rightarrow 0$.

Pf: $f \in C(-\infty, +\infty)$ 且 $f > 0, \exists K_1$ s.t. $Pr(z \in K_1^c) \rightarrow 0, M \rightarrow +\infty$, 设 $\inf_{z \in K_1} f(z) = l_0$

$A_\varepsilon^f = \{z: |\hat{f} - f| \geq \frac{l_0}{2}\} \Rightarrow E\|\hat{f} - f\|^2 \geq (\frac{l_0}{2})^2 P(A_\varepsilon^f)$, 由题意, $P(A_\varepsilon^f) \rightarrow 0$. 设 $\sup_{z \in K_1} f(z) = l_1$

$B_\varepsilon^f = \{z: |\hat{f}_0 - f| \geq \frac{l_1}{2}\} \Rightarrow P(B_\varepsilon^f) \rightarrow 0$, 故对充分大的 M, f, \hat{f} 有上下界, 除了一个测度很小的集合, f_0, \hat{f}_0 同理. 故 $\exists 0 < l_a < l_b < \infty$ 对充分大的 M 和 A_ε (低概率集), 有

$$0 < l_a < \inf_{z \in A_\varepsilon} \min\{f_0, \hat{f}_0, f, \hat{f}\} < \sup_{z \in A_\varepsilon} \max\{f_0, \hat{f}_0, f, \hat{f}\} < l_b < +\infty$$

$$\therefore \hat{T}_{OR} - T_{OR} = \frac{(1-\beta)\hat{f}_0}{\hat{f}} - \frac{(1-p)f_0}{f} = \frac{\hat{f}_0 f (p-\beta) + (1-p)f(\hat{f}_0 - f) + (1-p)f_0(f - \hat{f})}{\hat{f}f}$$

在 A_ε 上 (所有元素有界), 有 $(\hat{T}_{OR} - T_{OR})^2 \leq c_1(p-\beta)^2 + c_2(f_0 - \hat{f}_0)^2 + c_3(f_0 - f)^2$
易知 $\hat{T}_{OR}, T_{OR} \in (0, 1)$, 有界, 设为 L

$$\therefore E\|\hat{T}_{OR} - T_{OR}\|^2 \leq L P(A_\varepsilon) + c_1 E(p-\beta)^2 + c_2 E\|\hat{f} - f\|^2 + c_3 E\|\hat{f}_0 - f\|^2$$

$\because \hat{p} \in (0, 1)$ 有界. 易得 \hat{p} -致可积. 又 $\hat{p} \xrightarrow{P} p$, 故 $\hat{p} \xrightarrow{L^2} p$. 代入条件 $\hat{f}_0 \xrightarrow{L^2} f_0, \hat{f} \xrightarrow{L^2} f$
有 $E\|\hat{T}_{OR} - T_{OR}\|^2 \rightarrow 0$.

NOTE. 已证 $\hat{T}_{OR} \xrightarrow{L^2} T_{OR}$, 由 Markov 不等式有 $\hat{T}_{OR} \xrightarrow{P} T_{OR}$, 进而 $\hat{T}_{OR} \xrightarrow{D} T_{OR}$. 由弱收敛定义, 对 h 有界连续函数 h , 有 $Eh(\hat{T}_{OR}) \rightarrow Eh(T_{OR})$, 取 $h(x) = I\{x < t\}x$ (间断点可数)

得到 $E\{I(\hat{T}_{OR}(z_i) < t) \hat{T}_{OR}(z_i)\} \rightarrow E\{I(T_{OR}(z_i) < t) T_{OR}(z_i)\}$

引理二. 设 $\hat{G}_{OR}(t) = \frac{1}{m} \sum_{i=1}^m I(\hat{T}_{OR}(z_i) \leq t)$, $\hat{G}_{OR} = \frac{1}{m} \sum_{i=1}^m I(\hat{T}_{OR}(z_i) \leq t) \hat{T}_{OR}(z_i)$, 定义 $\hat{Q}_{OR}(t) = \frac{\hat{G}_{OR}(t)}{\hat{G}_{OR}(t)}$
即 MFR 估计, 对于 $\alpha < t < 1$, 有 $\hat{Q}_{OR}(t) \xrightarrow{P} Q_{OR}(t)$

NOTE: 用 $\hat{G}_{OR}(t)$ 估计 $(1-p)G_{OR}(t)$ 的原因: $(1-p)G_{OR}(t) = (1-p) \int_{T_{OR}(z) \leq t} f_0(z) dz = \int I(T_{OR}(z) \leq t) T_{OR}(z) f(z) dz$

由此得到 $\hat{Q}_{OR}(t) = \frac{[\frac{1}{m} \sum_{i=1}^m I(\hat{T}_{OR}(z_i) \leq t) \hat{T}_{OR}(z_i)]}{[\frac{1}{m} \sum_{i=1}^m I(\hat{T}_{OR}(z_i) \leq t)]}$, $\hat{Q}_{OR}(L(fdr(R))) = \frac{1}{R} \sum_{i=1}^R (fdr(i))$

Pf: 设 $\rho_m = \text{COV}(\hat{T}_{OR}(z_i), \hat{T}_{OR}(z_j)), z_i, z_j$ 相互独立且分布为 F , 由 $\hat{T}_{OR}(z_i) \xrightarrow{P} T_{OR}(z_i)$ 得

$E(\hat{T}_{OR}(z_i) \hat{T}_{OR}(z_j)) \rightarrow E(T_{OR}(z_i) T_{OR}(z_j))$, 即 $\rho_m \rightarrow \text{COV}(T_{OR}(z_i), T_{OR}(z_j)) = 0$, 设 $\sigma_m^2 = \text{Var}(\hat{T}_{OR}(z_i))$

则由 $\hat{T}_{OR}(z_i) = \frac{(1-\beta)\hat{f}_0}{\hat{f}} \wedge 1 \leq 1$ 得, $\sigma_m^2 \leq E(\hat{T}_{OR}(z_i))^2 \leq 1$

设 $u_m = P(\hat{T}_{OR}(z_i) < t)$, $S_m = \sum_{i=1}^m I(\hat{T}_{OR}(z_i) \leq t)$, 由方差展开式可得

$$\frac{\text{Var}(S_m)}{m^2} = \frac{1}{m} \sigma_m^2 + \frac{(m-1)}{m} \rho_m \leq \frac{1}{m} + \rho_m \rightarrow 0. \text{ 由弱大数定律得 } \frac{1}{m} \sum_{i=1}^m I(\hat{T}_{OR}(z_i) \leq t) \xrightarrow{P} u_m \xrightarrow{P} 0$$

又 $u_m \rightarrow P(T_{OR}(z_i) < t) = G_{OR}(t)$, $\therefore \hat{G}_{OR}(t) \xrightarrow{P} G_{OR}(t)$, 类似证 $\hat{G}_{OR}(t) - v_m \xrightarrow{P} 0$, 其中

$v_m = E(I(\hat{T}_{OR}(z_i) \leq t) \hat{T}_{OR}(z_i))$, 由上述 NOTE 有 $E(I(\hat{T}_{OR}(z_i) \leq t) \hat{T}_{OR}(z_i)) \rightarrow E(I(T_{OR}(z_i) \leq t) T_{OR}(z_i))$

$\therefore v_m \rightarrow E(I(T_{OR}(z_i) \leq t) T_{OR}(z_i)) = (1-p) \int I(T_{OR}(z_i) \leq t) f_0 dz = (1-p) G_{OR}(t)$

$\therefore \hat{G}_{OR}(t) \xrightarrow{P} (1-p) G_{OR}(t)$. 对于 $t > \alpha, G_{OR}(t) \geq \varepsilon > 0$. 故有 $\hat{Q}_{OR}(t) \xrightarrow{P} \frac{(1-p) G_{OR}(t)}{G_{OR}(t)} = Q_{OR}(t)$

依概率收敛的性质



引理三. 定义 $\hat{\lambda}_{OR} = \sup\{t \in (0,1) : \hat{Q}_{OR}(t) \leq \alpha\}$. 若 $\hat{Q}_{OR}(t) \xrightarrow{P} Q_{OR}(t)$, 则 $\hat{\lambda}_{OR} \xrightarrow{P} \lambda_{OR}$.
Pf: 注意到 $\hat{Q}_{OR}(t)$ 是不连续的, 故 $\hat{Q}_{OR}(t)$ 的相合性推不出 $\hat{\lambda}_{OR}$ 的相合性. 构造.

$\hat{Q}_{OR}^-(t), \hat{Q}_{OR}^+(t)$ 如下, 当 $Lfdnck < t < Lfdnck+1$ 时.

$$\hat{Q}_{OR}^-(t) = \frac{Lfdnck+1-t}{Lfdnck+1-Lfdnck} \hat{Q}_{OR}(Lfdnck+1) + \frac{t-Lfdnck}{Lfdnck+1-Lfdnck} \hat{Q}_{OR}(Lfdnck) \quad \text{滞后+线性连接}$$

$$\hat{Q}_{OR}^+(t) = \frac{Lfdnck+1-t}{Lfdnck+1-Lfdnck} \hat{Q}_{OR}(Lfdnck) + \frac{t-Lfdnck}{Lfdnck+1-Lfdnck} \hat{Q}_{OR}(Lfdnck+1) \quad \text{线性连接}$$

$$\Delta \text{ 有 } \hat{Q}_{OR}(Lfdnck+1) - \hat{Q}_{OR}(Lfdnck) = \frac{1}{k+1} [kLfdnck+1 - \sum_{i=1}^k Lfdnck_i] > 0$$

显然有 $\hat{Q}_{OR}^-(t) \leq \hat{Q}_{OR}(t) \leq \hat{Q}_{OR}^+(t)$, 且 $\hat{Q}_{OR}^-(t)$ 和 $\hat{Q}_{OR}^+(t)$ 为 t 的严格增函数, 定义.

$\hat{\lambda}_{OR}^- = \sup\{t \in (0,1) : \hat{Q}_{OR}^-(t) \leq \alpha\}$. $\hat{\lambda}_{OR}^+ = \sup\{t \in (0,1) : \hat{Q}_{OR}^+(t) \leq \alpha\}$, 则有 $\hat{\lambda}_{OR}^- \leq \hat{\lambda}_{OR} \leq \hat{\lambda}_{OR}^+$

断言 $\hat{\lambda}_{OR}^- \xrightarrow{P} \lambda_{OR}$. 否则 $\exists \varepsilon_0, \gamma_0$ s.t. $P(|\hat{\lambda}_{OR}^- - \lambda_{OR}| > \varepsilon_0) > 2\gamma_0$. $\forall m \geq M$, 必有 $P(\hat{\lambda}_{OR}^- > \lambda_{OR} + \varepsilon_0) > \gamma_0$
且 $\hat{Q}_{OR}^- \xrightarrow{P} Q_{OR}$ (格里的科定理). ($\because \hat{Q}_{OR}^-(t) - \hat{Q}_{OR}^+(t) \xrightarrow{a.s.} 0$ SLLN. $\hat{Q}_{OR}^-(t) \leq \hat{Q}_{OR}(t) \leq \hat{Q}_{OR}^+(t) > 2\gamma$
且 $\hat{Q}_{OR}^-(t) \xrightarrow{P} \hat{Q}_{OR}(t)$)

$$\therefore \forall m \geq M. P(|\hat{Q}_{OR}^-(\lambda_{OR} + \varepsilon_0) - Q_{OR}(\lambda_{OR} + \varepsilon_0)| < \delta_0) > 1 - \gamma_0, \quad 2\delta_0 = Q_{OR}(\lambda_{OR} + \varepsilon_0) - \alpha$$

$$\text{设 } K_{1m} = \{w : |\hat{Q}_{OR}^-(\lambda_{OR} + \varepsilon_0) - Q_{OR}(\lambda_{OR} + \varepsilon_0)| < \delta_0\}, \quad K_{2m} = \{w : \hat{\lambda}_{OR}^- > \lambda_{OR} + \varepsilon_0\}.$$

$$P(K_{1m}) > 1 - \gamma_0. \quad P(K_{2m}) > 2\gamma_0. \quad K_m = K_{1m} \cap K_{2m}. \quad P(K_m) \geq 1 - \gamma_0 + 2\gamma_0 - 1 = \gamma_0 > 0.$$

$$\text{在 } K_m \text{ 中, } \alpha < \hat{Q}_{OR}^-(\hat{\lambda}_{OR}^-) \leq \hat{Q}_{OR}^-(\lambda_{OR} + \varepsilon_0) < Q_{OR}(\lambda_{OR} + \varepsilon_0) - \delta_0 \leq \delta_0 + \alpha. \quad \text{矛盾.}$$

$$\text{同理 } \hat{\lambda}_{OR}^+ \xrightarrow{P} \lambda_{OR}. \quad \because \hat{Q}_{OR}^+(t) - \hat{Q}_{OR}^-(t) \xrightarrow{a.s.} 0. \Rightarrow \hat{\lambda}_{OR}^+ - \hat{\lambda}_{OR}^- \xrightarrow{a.s.} 0. \Rightarrow \hat{\lambda}_{OR}^- - \hat{\lambda}_{OR} \xrightarrow{a.s.} 0.$$

由 Slutsky 定理. $\hat{\lambda}_{OR} \xrightarrow{P} \lambda_{OR}$.

定理三的证明: 依方法相同于用 $\hat{T}_{OR}(z_i)$ 为检验统计量, $\hat{\lambda}_{OR}$ 为阈值. 则 $\delta(\hat{T}_{OR}(z_i), \hat{\lambda}_{OR})$ 的

$$mFDR = \frac{E(N_{01})}{E(R)} = \frac{(1-p)P_{H_0}(\hat{T}_{OR} < \hat{\lambda}_{OR})}{P(\hat{T}_{OR} < \hat{\lambda}_{OR})} \xrightarrow{P} \frac{(1-p)P_{H_0}(T_{OR} < \lambda_{OR})}{P(T_{OR} < \lambda_{OR})} = \frac{(1-p)Q_{OR}(\lambda_{OR})}{Q_{OR}(\lambda_{OR})} = Q_{OR}(\lambda_{OR}) = \alpha$$

定理四的证明: 同上.

$$mFNR = \frac{E(N_{01})}{E(S)} = \frac{P_{H_1}(\hat{T}_{OR} > \hat{\lambda}_{OR})}{P(\hat{T}_{OR} > \hat{\lambda}_{OR})} \xrightarrow{P} \frac{P_{H_1}(T_{OR} > \lambda_{OR})}{P(T_{OR} > \lambda_{OR})} = \frac{P(\tilde{Q}_{OR}(\lambda_{OR}))}{\tilde{Q}_{OR}(\lambda_{OR})} = \tilde{Q}_{OR}(\lambda_{OR})$$

NOTE: 注意说明分母 $\geq \varepsilon > 0$. 利用依概率收敛的性质.



4. 方法步骤.

① Oracle Procedure:

Step 1: 计算 z 值.

Step 2: 计算 local fdr $T_{OR}(z_i) = \frac{(1-p)f_0(z_i)}{f(z_i)}$, $i=1, \dots, m$

p, f_0, f, G_{OR}
 G_{OR} 需要估计

Step 3: 计算 $\lambda_{OR} = \sup \{t \in (0, 1) : Q_{OR}(t) \leq \alpha\}$, $Q_{OR}(t) = \frac{(1-p)G_{OR}(t)}{G_{OR}(t)}$

Step 4: 记 $\mathcal{H} = \{i : I(T_{OR}(z_i) < \lambda_{OR}) = 1\}$. 拒绝 H_i , $i \in \mathcal{H}$.

② Data-driven Procedure:

Step 1: 计算 z 值.

Step 2: 用 Jin, Cat(2007) 方法估计 \hat{p} , \hat{f}_0 , \hat{f} .

Step 3: 计算 local fdr $\hat{T}_{OR}(z_i) = \frac{(1-\hat{p})\hat{f}_0(z_i)}{\hat{f}(z_i)}$, $i=1, \dots, m$. 并排序得到 $Lfdr(1), \dots, Lfdr(m)$.

Step 4: 计算 $k = \max \{i : \hat{Q}_{OR}(Lfdr(i)) = \frac{1}{2} \sum_{j=1}^i Lfdr(j) \leq \alpha\}$. 拒绝 $H_{(1)}, \dots, H_{(k)}$.