



Locally Adaptive Weighting and Screening (LAWS)

1. 改进目标: 本文适用于spatial数据推断, 应用LAWS去直接包含局部特征^性推断, 其可以应用在很多空间数据上且是^{完全}数据驱动. 可用在2D/3D图像上. 常常相依结构被认为是一个先验或从~~其中~~数据中可以较好地估计. 这样会有一些问题: (1) 先验是错误的, (2) 估计的优劣取决于是否满足假设, (3) 相依结构导致了强的正则化条件和繁冗的计算成本.

① 本文的目标: 提出一种能自适应学习数据中的稀疏结构在潜在的空间过程中的FDR控制方法. 主要的想法是利用辅助信息去重构多重检验问题.

② LAWS首先用screening方法估计局部的稀疏结构, 其次构建空间权重去调整p值, 最后选择p值去调整多重性. LAWS会在信号多的地方上调p值, 反之下调p值.

③ 大范围尺度检验, 若利用辅助信息, 以前的文献由 (1) 在原数据构建辅助统计量 (2) 外部数据或先验. 我们区别于这两种方法, 用空间次序去反映局部的类似或渐性, 而不是利用定性/定量变量去分析. 注: grouping分析不适用于空数据分析因为分成几个好的组需要好的先验或繁冗的计算. 且分组涉及到离散一个连续性变量, 会造成信息损失.

④ 优点: (1) 应用广泛, 2D-3D图. (2) 由最优化理论导出, 有扎实的理论基础. (3) 完全数据驱动且提供了一种客观的方法去包含side information. (4) 证明LAWS有效的时候给了一种不同的证明.

⑤ 定义稀疏程度 $\pi(s) = P(\theta(s) = 1)$, 其光滑性提供了关键的结构信息, 可以通过整合其邻近点的信息, 进而构造更有效的方法. LAWS属于一种加权方法. 根据CLF定义, 由CAPS得其等价于一个加权分类问题. $CLFdn = \frac{1}{\lambda n}$, $\lambda = \frac{1 - \pi(s)}{\pi(s)} \frac{f_0}{f_1}$. 关于 λ 单调, 而 λ 中包含两种信息.

(1) 稀疏结构: 信号有多频繁出现在 s 的邻域. $\frac{1 - \pi(s)}{\pi(s)}$, (2) 数据本身反映出该点是属于null的信息, 似然比. $\frac{f_0(x|s)}{f_1(x|s)}$. 因为后者很难计算, 提出用p值去替代, 权重为 $\frac{1 - \pi(s)}{\pi(s)}$.

$p(s) = \min\left\{\frac{1 - \pi(s)}{\pi(s)} p(s), 1\right\} = \min\left\{\frac{p}{w}, 1\right\}$. π 大, $p(s)$ 小. BH控制FDR为 $(1 - \alpha)\alpha$. 证明 π 可以提高Power. 要注意, 加权后密度会发生变化.

⑥ 要去估计一些量. 如 $\pi(s)$ 以及 τ_{α} . 我们首先利用核光滑的非参数方法, 然后用数据估计 τ_{α} . $\pi^*(s) = 1 - \frac{P(p(s) > \tau)}{1 - \tau}$, $\tau \in (0, 1)$, 且 $\frac{\pi^*(s) - \pi(s)}{\pi(s)} = -\frac{1 - G_1(\tau|s)}{1 - \tau} < 0$. $\pi^*(s)$ 为保守估计. 要去估计 $\pi^*(s)$.

(1) Smoothing and screening, $\hat{\pi}^*(s) = 1 - \frac{\sum_{s' \in T} V_h(s, s')}{(1 - \tau) \sum_{s' \in T} V_h(s, s')}$, $T = \{s \in S, p(s) > \tau\}$, $V_h(s, s') = \frac{K_h(s - s')}{K_h(0)}$. K 为核函数. (2) 进而, 有 $\hat{w}(s) = \frac{\hat{\pi}(s)}{1 - \hat{\pi}(s)}$, 为了便算法稳定, 令 $\hat{\pi}(s)$ 限制在 $(\nu, 1 - \nu)$ 内, ν 很小. (3) 因为错误发现数的期望 $EFP = \sum P(p(s) \leq \tau_{\alpha} | \theta(s) = 0) P(\theta(s) = 0) = \sum \pi(s) \tau_{\alpha}$. 则若拒绝 q 个假设, 则大约有 $\frac{1}{q} \sum \pi(s) p_{q,i}$ 个假阳. 则 $FDP = \frac{1}{q} \sum \pi(s) p_{q,i}$.

2. 方法步骤: Step 1: 由计算 $\hat{\pi}(s)$, $\hat{w}(s)$ 以及各p值和调整p值 p^w , 并排序.

Step 2: 令 $k^w = \max\{q: \frac{1}{q} \sum \hat{\pi}(s) p_{q,i} \leq \alpha\}$

Step 3: 拒绝 $H_{w_1}, \dots, H_{w_{k^w}}$



3. 假设前提

- (1) 设 $\pi^T(\cdot)$ 有连续的二阶偏导数, 存在 $C > 0$ s.t. $-C \leq \lambda_{\min}(S) \leq \lambda_{\max}(S) \leq C, \forall S$. 其中 $\lambda_{\min}, \lambda_{\max}$ 分别表示最小和最大特征值 (黑塞矩阵)
- (2) 设 $\text{Var}(\sum I(p(S) > \tau)) \leq C' \sum \text{Var}(I(p(S) > \tau))$. 对某个常数 $C' > 1$.
- (3) $(n, g)_{m \times m} = R = \text{corr}(Z)$. 设 $\max_{k, l < g \leq m} |R_{kl}| \leq r < 1, r > 0$. 进而, $\exists r' > 1$ s.t. $\max_{1 \leq i \leq m, \theta_{iS} = 0} |\tau_i(r)| = o(m^R)$, 其中 $0 < R < \frac{1-r}{1+r}$, 其中 $\tau_i(r) = \{j: 1 \leq j \leq m, |R_{ij}| \geq (\log m)^{-2-r'}\}$
- (4) $\exists \xi > 0$ s.t. $\pi^T(S) \in [\xi, 1-\xi]$, 且 $\text{Var}[\sum I(\theta_{iS} = 0)] = O(m^{1+\xi})$, $\xi \in [0, 1)$
- (5) 定义 $S_0 = \{i: 1 \leq i \leq m, |u_i| \geq (\log m)^{\frac{1+\xi}{2}}\}$, $u_i = E(Z_i)$. 对 $\rho > 0, \delta > 0, |S_0| \geq \frac{1}{\rho} + \delta \sqrt{\log m}$.

NOTE: (1) 是对 Alternative CDF $Q^N(S)$ 的 mild regularity condition.
(2) 假设大部分 p 值是弱相关的. (3) 假设了大部分 null p 值是弱相关的 - 允许一部分强相关且没有对 nulls 施加条件. (4) θ_{iS} 不是完全相关, 可以高度相关.

4. 理论结果. \rightarrow 说明 δ_{OR}^w - 致优于 δ_{OR}' , 由定义可知 $Q^N(t_{\text{OR}}) \leq \alpha$. 证明的是 $w(S)$ 的好!

Thm 1 (Oracle). 设 $\frac{\sum \pi(S)}{\sum (1 - \pi(S))} \leq 1, \forall S \in \mathcal{S}$, 若 $t \rightarrow G(t|S)$ 且 $x \rightarrow G(\frac{x}{\pi(S)}|S)$, $\forall \min w^-(S) \leq x \leq \max w^+(S)$

则有 (a) $Q^N(t_{\text{OR}}) \leq Q^I(t_{\text{OR}}) \leq \alpha$ (b) $\Psi^N(t_{\text{OR}}) \geq \Psi^I(t_{\text{OR}}) \geq \Psi(t_{\text{OR}})$

Prop 1 (Estimate $\pi(S)$). 在 (1), (2) 成立下, $\forall S \in \mathcal{S}, E[\hat{\pi}^T(S) - \pi^T(S)]^2 \rightarrow 0, S \rightarrow \mathcal{S}$

Thm 2 (Oracle LAWS) 在 (3), (4), (5) 下, $\forall \varepsilon > 0, \limsup_{m \rightarrow \infty} \text{FDR}(\delta^w) \leq \alpha, \lim_{m \rightarrow \infty} P(\text{FDP}(\delta^w) \leq \alpha + \varepsilon) = 1$

Thm 3 (Data-Driven) 在 Prop 1, Thm 2 条件下, $\forall \varepsilon > 0, \limsup_{m \rightarrow \infty} \text{FDR}(\delta^w) \leq \alpha, \lim_{m \rightarrow \infty} P(\text{FDP}(\delta^w) \leq \alpha + \varepsilon) = 1$